



Nerual.Dreming

Искусственный интеллект

...

Нейросеть от Microsoft для транскрипции видео, которая понимает кто говорит: VibeVoice ASR — обзор и портативная версия для Windows

5 дней назад

15K

[моё]

Нейронные сети

Искусственный интеллект

Microsoft

Распознавание

...

Всем привет! Команда **Microsoft Research** выложила в открытый доступ **VibeVoice-ASR** — нейросетевую модель для распознавания речи с диаризацией (разделением) спикеров. Сегодня хочу рассказать об этой технологии подробнее и поделиться портативной версией.

Пикабу • 00:37

Меня зовут Илья, я основатель сервиса для генерации изображений **ArtGeneration.me**, блогер и просто фанат нейросетей. А ещё я собрал портативную версию VibeVoice ASR под Windows и успел её как следует протестировать.



user6337865



360

магазин

Задания

Все

Поставить плюсы к 5
постам в Горячем

+10

Задание дня • Лёгкое

16 295 рейтинг

10 подписчиков

Ответы

Комментарии

Оценки

Сохраненные

Просмотренное

Управление подписками

Черновики

Монетизация

Пикабу+

Редактирование тегов

Промокоды

Работа

Курсы

Реклама

Игры


Пополнение Steam



Пикабу Игры

+1000 бесплатных онлайн и...





Кулинарные истории
Казуальные, Новеллы, Симуляторы

Играть

Реклама

Получите гражданство Болгарии.
От 18 месяцев
proemigra.com

8 000 EUR -20% 10 000 EUR

Перейти

Реклама • 16+

Найдите работника быстро на hh.
и
hh.ru

Перейти

Топ прошлой недели

- Animalrescued
47 постов
- kka2012
17 постов
- Bezakaliarsandr
2 поста

Посмотреть весь топ

Лучшие посты недели


Whisper которому уже года три

Я сам пользуюсь Whisper уже много лет — делаю транскрипции своих видео, чтобы потом собрать оглавление для YouTube и использовать материал в текстовых статьях. И скажу честно — никогда не был полностью доволен результатом. Да, Whisper быстрый. Но на этом его достоинства для меня заканчивались.

Поэтому к изучению VibeVoice ASR я подошёл со всей ответственностью — протестировал на разных записях, сравнил качество, покрутил настройки.

Главная особенность системы в том, что она обрабатывает **до 60 минут аудио за один проход** без нарезки на чанки. На выходе — структурированная транскрипция с указанием кто говорит, когда и что именно сказал. И всё это работает локально на вашем компьютере.

Как это работает



В основе VibeVoice-ASR лежит архитектура на базе Qwen 2.5 (~9 млрд параметров).
Ключевая инновация — двойная система токенизации с ультранизким frame rate 7.5 Hz: акустический и семантический токенизаторы.

Такой подход позволяет модели работать с контекстным окном в 64К токенов — это и даёт возможность обрабатывать целый час аудио без потери контекста. Для сравнения: Whisper режет аудио на 30-секундные кусочки и теряет связность на границах сегментов.

На выходе модель генерирует Rich Transcription — структурированный поток с тремя компонентами:

```
[{"Start":0,"End":1.51,"Content":["Environmental Sounds"]},
{"Start":1.51,"End":7.49,"Speaker":0,"Content":"У неё преждевременное сохранять невозможно, родила, начала сразу родильная деятельность."},
{"Start":7.51,"End":9.41,"Speaker":1,"Content":"Марина, что с ней?"},
{"Start":10.28,"End":16.22,"Speaker":0,"Content":"У неё преждевременное сохранять невозможно, отошли годы, начала, начала сразу родовая деятельность."},
{"Start":16.22,"End":18.02,"Speaker":1,"Content":"Марина, что с ней?"},
{"Start":18.13,"End":27.94,"Speaker":0,"Content":"Она рождает, привезли в ближайшую больницу родовую. В каком состоянии ребёнок ещё хуже, срок маленький."},
```

Помимо спикеров, модель размечает неречевые события: [Music], [Silence], [Noise], [Human Sounds] (смех, кашель), [Environmental Sounds], [Unintelligible Speech]. Это сделано чтобы модель не галлюцинировала текст во время пауз или фоновой музыки.

Рассылка Пикабу: отправляем самые рейтинговые материалы за 7 дней 🔥

Укажите E-mail

Подписаться

Нажимая «Подписаться», я даю согласие на обработку данных и условия почтовых рассылок.

РЕКЛАМА

ССК

КОРСАКОВ

ИНВЕСТИЦИИ С ВИДОМ НА УСПЕХ!

от 11 млн р

вход от 2,3 млн р

РАССРОЧКА!

доход от 2 млн р/год

Застройщик ООО «СЗ «ДомСтройАнапа» ИНН 2312320144. Проектная декларация на сайте наш.дом.рф sskuban.ru. Подробная информация в отделе продаж и на сайте https://sskuban.ru/. Н является публичной офертой.

- Помощь
- Правила соцсети
- Кодекс Пикабу
- О рекомендациях
- Команда Пикабу
- О компании
- Моб. приложение

- Промокоды Биг Гик
- Промокоды Lamoda
- Промокоды МВидео
- Промокоды Яндекс Маркет
- Промокоды Пятерочка
- Промокоды Aroma Butik
- Промокоды Яндекс Путешествия
- Промокоды Яндекс Еда
- Постила
- Футбол сегодня



Возможности VibeVoice ASR

Меньше значит лучше

- **Обработка длинных записей:** до 60 минут аудио за один проход без потери контекста. Идеально для митингов, подкастов, лекций.
- **Диаризация спикеров:** автоматическое определение кто говорит в каждый момент времени. Работает на записях с несколькими участниками.
- **Временные метки:** точные таймкоды для каждого сегмента речи. Готовый материал для субтитров.
- **Customized Hotwords:** вот что меня реально зацепило — возможность задать пользовательский контекст. Перед распознаванием указываешь список слов: фамилии, названия продуктов, термины, сокращения. Всё то, что обычно произносится нестандартно и превращается в кашу. Если в видео часто звучит "ArtGeneration" или "НЕЙРО-СОФТ" — просто добавляешь в контекст, и модель ВСЕГДА распознаёт корректно. Для технического контента — просто спасение.
- **51 язык:** включая русский, хотя основной фокус на английском и китайском.



Набор языков отличный

Модели

Помимо оригинальной модели от Microsoft, сообщество уже сделало квантованные версии для видеокарт с меньшим объёмом памяти.

Полная модель — [microsoft/VibeVoice-ASR](#) Размер 17.3 GB, требует ~8 ГБ VRAM. Лучшее качество распознавания.



4-bit квантизация — [scerz/VibeVoice-ASR-4bit](#) Требуется ~4 ГБ VRAM, немного медленнее.

Подходит для видеокарт с меньшим объёмом памяти.

В моей портативке доступны обе версии — можно выбрать прямо в интерфейсе. Также есть эмуляция 4-bit квантизации для полной модели, если хотите попробовать оригинал, но памяти впритык.

Текущие ограничения

К сожалению, не все задачи система решает одинаково хорошо:

- **Перекрывающаяся речь:** если два человека говорят одновременно, модель не разделит их корректно.
- **Короткие фрагменты:** диаризация плохо работает на высказываниях менее 1 секунды.
- **Только batch processing:** нет real-time режима, только обработка готовых файлов.
- **Ресурсоёмкость:** требует достаточно мощную видеокарту для комфортной работы.

Кому это пригодится



Пикабу • 00:43

Подкастерам и интервьюерам: автоматические субтитры с разделением спикеров.

Загрузили часовой выпуск — получили готовую разметку.

Создателям контента: генерация SRT-субтитров для YouTube без ручного тайм-кодирования.

Бизнес-аналитикам: транскрипция часовых созвонов и совещаний с сохранением контекста и указанием кто что говорил.

Разработчикам: base model для фанттюнинга под специфичные домены — медицина, юриспруденция, техподдержка.

Как попробовать

Онлайн-демо



Почему-то не додумались сделать парсер json текста

Онлайн-демо: <https://4e47b675ea4015a607.gradio.live/>

Официальное демо от Microsoft — можно потестить прямо сейчас без установки.

Установка с Github

Как-то сложно



Официальный GitHub: <https://github.com/microsoft/VibeVoice>

HuggingFace модель: <https://huggingface.co/microsoft/VibeVoice-ASR>

Портативная версия

Пикабу • 00:42

Я с каналом Нейро-Софт подготовил портативную сборку VibeVoice ASR Portable RU.

В ней:

- Русифицированный интерфейс
- Установка в один клик (install.bat)
- Поддержка полной и 4-bit моделей
- Парсер результатов с фильтрацией — можно отдельно включать/выключать временные метки, спикеров, дескрипторы (музыка, шум, тишина). Удобно когда нужен только чистый текст без разметки
- Фильтр по спикерам — можно вывести текст только конкретного участника разговора
- Выбор видеокарты и установка нужной версии CUDA
- Flash Attention 2 для RTX 30xx/40xx/50xx
- Поддержка всех форматов аудио и видео через FFmpeg
- Тёмная тема интерфейса



Всё необходимое уже включено в дистрибутив, просто распакуйте и запускайте, есть версия с готовым окружением под win 11 и RTX4090. [Забирайте архив тут.](#)

Или установите с GitHub: https://github.com/timoncool/VibeVoice_ASR_portable_ru

Системные требования

- NVIDIA GPU с 8+ ГБ видеопамяти (или 4+ ГБ для 4-bit модели)
- Windows 10/11 64-bit
- 16 ГБ оперативной памяти
- 10 ГБ свободного места на диске

Распакуйте в любую папку (путь без кириллицы), запустите install.bat, выберите видеокарту из списка. Модели скачаются при первом запуске.

Рассказывайте в комментариях как вы могли бы использовать такой инструмент и чего не хватает.

Я рассказываю больше о нейросетях у себя на YouTube, в Телеграм и на Бусте. Буду рад вашей подписке и поддержке. На канал Нейро-Софт тоже подпишитесь, чтобы не пропустить полезные репаки. Всех обнял. Удачных транскрипций!

👍 10 🐼 2 ❤️ 2 💩 1 😊

💬 25 📁 🔄



Искусственный интеллект

5.3K постов 11.7K подписчиков

[Добавить пост](#)

[Отписаться](#)

...

Правила сообщества

ВНИМАНИЕ! В сообществе запрещена публикация генеративного контента без детального описания промтов и процесса получения публикуемого результата.

...

[Подробнее](#) ✓



rabotadar РЕКЛАМА

**Работа в Тель
Авиве**

[Узнать больше](#)



romanesc РЕКЛАМА

**Оформить
паспорт
Румынии
от 4 000 €**


[Узнать больше](#)



proemigra. РЕКЛАМА

**Получите
гражданство
Болгарии. От 18
месяцев
8 000 € -20%
10 000 €**

[Узнать больше](#)



hh.ru РЕКЛАМА

**Найдите
работника
быстро
на hh.ru**

[Узнать больше](#)



Все комментарии Автора

▲ 3 ▼

darikcr настрочил 5 дней назад

Работа классная!

Статья перегружена, на мой взгляд, крупными цельногенерированными кусками.

Документацию не обязаельно пересказывать, хватит ссылки на Github на раздел How to install :)

Это не хабр всё же) да и ам не обязаельно копировать, ценность имеют комментарии

❤️ 2 😊

ответить

▲ 3 ▼

Barberrys 5 дней назад ❤️

Жаль её не было когда в универе училась, записывая 5-часовые лекции без остановки..

Отвлёкся на минуту и уже половина потеряна

❤️ 😊

ответить

▲ 2 ▼

academica 5 дней назад

Надеюсь дожить до того дня, когда фильмы и сериалы в многоголосой русской озвучке будут появляться буквально на следующий день после релиза.

Причем русские голоса будут с тем же тембром, интонацией и другими характеристиками, что и в оригинале

❤️ 😊

ответить



▲ 0 ▼

termalix 3 дня назад

Посмотри у автора на гитхабе timonsool две недели как квен 3 со всеми плюшками есть, вот не за горами это все. Я больше переживаю как теперь по моим голосовым могут получить мой голос и отправлять родным, вот что опасно стало.

❤️ 😊

ответить

▲ 1 ▼

Megabotanl 4 дня назад

Протестировал я результат не в пользу этой модели. Whisper лучше распознает, а у этой сборки гораздо больше ошибок. И работает дольше.

Но за старания автору спасибо. Сборка интересная.

❤️ 😊

ответить

Раскрыть 20 комментариев



Почему я вижу рекламу?

Реклама romanesc.ru



Оформить паспорт Румынии

Иммиграционная помощь по оформлению гражданства ЕС. Оставляйте заявку на сайте!

